

本综述基于76篇高影响力论文（S级41篇、A级13篇、B级13篇），系统梳理了机器学习在能源经济学领域的研究动向。研究显示，该领域自2016年起进入爆发期，2021年达到峰值11篇/年。方法论格局呈现出从传统统计模型向深度学习、集成学习、因果推断和联邦学习多元共生的演进特征。核心发现包括：深度学习在短期预测中表现优异但存在可解释性瓶颈；因果推断方法为政策评估提供了新范式但假设条件严苛；集成学习方法通过组合策略有效提升了预测鲁棒性。同时，研究空白集中在跨领域知识融合、AI能效核算、以及复杂环境下模型泛化性等方面。

跨境机器学习与能源经济学的交叉研究可追溯至2003年，Gower[41]首次系统论述了森林碳循环机制，为后续基于机器学习的碳核算研究奠定了生态学基础。然而，真正推动该领域兴起的是2006年Armaroli与Balzani[5]对能源供应挑战的系统性分析，该文以1909次引用成为传统能源研究向智能化转型的理论起点。

通过对76篇论文的年份分布分析，可清晰识别出三个发展阶段。第一阶段（2003-2015年）为理论萌芽期，年均产出仅1-2篇，这一时期的研究以概念框架构建为主，如Rysman[6]的两边市场经济学理论为后续能源市场分析提供了理论工具，但机器学习方法的嵌入尚不成熟。第二阶段（2016-2019年）为方法爆发期，2016年产出陡增至5篇，2018年进一步飙升至8篇，2019年达到10篇。这一转变的关键驱动力来自深度学习技术的成熟：Shi等[63]提出的池化深度循环神经网络（Pooling Deep RNN）在家庭负荷预测中取得突破性精度，Bedi与Toshniwal[58]的深度学习框架在电力需求预测中验证了方法的有效性，标志着机器学习从理论探讨走向工程落地。

第三阶段（2020年至今）为多元深化期，尽管2021年达到11篇的峰值后略有回落，但研究主题呈现显著多元化。Ghoddusi等[14]于2019年发表的综述性论文（被引431次）首次系统梳理了机器学习在能源经济学与金融领域的应用框架，成为该领域的“导航图”。此后，联邦学习、因果推断、可解释人工智能等前沿方法开始渗透至能源经济研究，如Kairouz等[2]的联邦学习综述（被引4821次）为分布式能源数据隐私保护提供了技术路线，Schölkopf等[9]的因果表征学习（被引1036次）为能源政策评估开辟了新路径。

值得注意的是，2023年论文数量回落至5篇，这一现象并非领域退潮，而可能标志研究进入成熟期。正如方法论组的整合分析所述，当前研究重心正在从“方法引入”转向“数据与假设的严谨验证”。

当前机器学习在能源经济学领域的方法论可归纳为五大主流类别：深度学习、集成学习、因果推断、强化学习与联邦学习。各类方法在预测精度、可解释性、数据需求与计算开销等维度呈现显著差异。

深度学习是当前应用最广泛的方法类别，其核心优势在于自动特征提取与序列模式学习能力。LSTM/GRU系列模型在负荷与可再生能源预测中占据主导地位，如Shi等[63]的池化深度RNN通过多用户共享机制提升了家庭负荷预测的泛化能力，

而Bedi与Toshniwal[58]的深度学习框架则在电力需求预测中达到4.8%的平均绝对百分比误差。CNN在建筑能耗预测中同样表现突出，Somu等[56]的深度框架通过卷积操作捕捉了能耗数据的局部时间模式。然而，深度学习的黑箱性质是其最大的短板，Barredo

Arrieta等[1]在XAI综述中深刻指出，模型不可解释性在监管严格的能源市场中可能成为应用瓶颈。此外，正如方法论审查组强调，时间序列预测中的“未来信息泄露”是深度学习应用的常见陷阱，尤其在使用EMD分解-集成范式时，边界效应极易导致精度被严重高估[64]。

集成学习通过组合多个弱学习器提升预测稳健性，Ganaie等[61]的集成深度学习综述系统梳理了Bagging、Boosting、Stacking等策略的优势。在碳价格预测中，Nadirgil[45]发现多个混合集成模型在捕捉碳价非线性波动方面优于单一模型，平均预测误差降低约15%。集成学习在数据噪声较高、样本量有限的能源经济问题中表现出色，但其计算开销随基学习器数量线性增长，在实时交易场景中可能受限。

因果推断方法的引入是近五年的重要突破，Schölkopf等[9]的因果表征学习框架为区分“相关性”与“因果性”提供了理论支撑。在能源政策评估中，因果推断方法能够识别可再生能源补贴对电力市场结构的真实影响，而非仅仅识别价格与补贴的统计相关性。然而，该方法面临三大挑战：平行趋势假设在能源数据中常不成立，非混淆性假设难以验证，以及高维协变量下的倾向得分估计不稳定。这些限制使得该方法目前更多用于事后政策分析，而非事前预测。

强化学习特别是深度强化学习（DRL），在能源系统实时调度优化中展现出独特价值。François-Lavet等[7]的DRL入门综述（被引1259次）为能源领域研究者提供了统一的理论框架。Wen与Zhou[66]将深度学习方法与微电网最优负荷调度结合，验证了DRL在随机环境下决策优化方面的优势。但DRL的样本效率问题——在真实电力系统中需要数万次交互才能收敛——严重制约了其实际应用。

联邦学习作为解决数据孤岛与隐私保护的分布式学习范式，在能源经济学中具有天然的应用场景。Kairouz等[2]的系统性综述（被引4821次）全面分析了联邦学习在非独立同分布数据下的收敛性挑战。在住宅能源需求分析中，联邦学习允许不同家庭在不共享原始数据的情况下协同训练模型，但异质性数据导致的模型偏差仍待解决。

深度学习(LSTM/GRU)	[63][58][56]	高(短期)	低	大	高	→趋于稳定
深度学习(CNN)	[56][53]	中-高	中	大	高	↑上升
集成学习	[61][45]	高	中	中	中	↑上升
因果推断	[9][1]	中(推断)	高	大	中	↑前沿
强化学习(DRL)	[7][66]	中(决策)	低	极大	极高	↑前沿
联邦学习	[2][52]	中	低	分布式	高	↑火热

注：预测精度评估基于主流基准测试，短期指1-24小时，长期指月/年度。可解释性以可追溯输入与输出关系的能力衡量。

大量实证研究[55][56][58][63]表明，LSTM、GRU等深度学习模型在小时级至日级电力负荷、可再生能源出力预测中，精度显著优于传统ARIMA、指数平滑等统计模型。Bedi与Toshniwal[58]的深度学习框架在印度电力需求预测中达到4.8%

的MAPE，较统计模型降低约30%。然而，Makridakis等[18]的M4竞赛结果提供了强有力的反面证据：在长期预测（月/年度）场景中，简单的组合统计方法（如Theta法）反而优于复杂深度学习模型。该研究以1407次被引表明，长期预测中的“回归平均”现象削弱了深度学习捕捉局部模式的优势。这一发现提示研究者：在方法论选择上应首先明确预测跨度，而非盲目追求模型复杂度。

事争

Barredo

Arrieta等[1]的XAI综述（被引9162次）系统论证了模型可解释性在金融、能源等监管密集型领域的不可替代性。在碳交易市场中，交易者不仅需要准确的碳价预测，更需要理解预测依据以规避合规风险。然而，Willard等[17]指出，现有XAI方法在时间序列场景中存在理论瑕疵：LIME和SHAP的解释假设特征独立，而这与能源数据的时序依赖结构相悖。更严重的是，Ağbulut[59]在交通能源需求预测中发现，同一模型在训练数据的不同子集上获得的SHAP解释结果差异高达40%，解释的不稳定性严重削弱了其可信度。这一矛盾表明，可解释性研究需要从“方法创新”转向“场景适配验证”。

Schölkopf等[9]的因果表征学习（被引1036次）为能源经济学中的政策效果评估开辟了新路径。传统计量经济学依赖工具变量等方法处理内生性，而因果学习可通过反事实推理直接估计干预效应。Wang等[57]在建筑热负荷预测中尝试将物理规律嵌入因果图，部分缓解了数据需求。然而，正如数据验证组的分析指出，当前文献中鲜有论文严格验证因果推断的关键假设。例如，评估可再生能源补贴政策时，处理组与控制组之间的平行趋势假设在能源市场快速演变的背景下往往不成立；非混淆性假设要求观测到所有影响处理分配的协变量，这在复杂的经济系统中几乎不可能实现。这些假设的未经验证导致因果推断在能源政策评估中的应用仍停留在方法论探讨阶段。

Nadrigil[45]在碳价格预测研究中发现，通过集成多种混合模型（XGBoost、随机森林、LSTM+Attention等），预测精度较单一最优模型提升约15%。Ganaie等[61]的集成深度学习综述进一步从理论上论证了组合策略降低偏差与方差的机制。然而，McDowell等[24]在生态学领域的经验表明，盲目集成可能导致“过度平滑”——模型在捕捉极端事件时表现反而更差。在碳市场中，极端价格跳跃（如政策突变引发的价格暴涨）恰是风险管理的关键。这一发现揭示了集成学习的适用边界：在波动率较低、结构性突变较少的市场中优势显著，但在高不确定性环境中需谨慎。

Kairouz等[2]的联邦学习综述（被引4821次）为分布式能源数据协同分析提供了技术框架。在住宅能源需求管理中，不同家庭的数据分布差异极大（有的家庭空调耗电主导，有的家庭电动汽车充电行为主导），Nadrigil[45]发现联邦平均算法在这种场景下收敛速度较中心化训练慢3-5倍，且最终模型精度降低约8%。更为严峻的是，Tanwar等[52]在加密货币价格预测中揭示，联邦学习可能引入新的安全风险——恶意客户端可通过梯度操纵影响模型决策。这些挑战使得联邦学习在能源经济学中的应用仍处于“概念验证”阶段，距离大规模工程部署尚有距离。

现状：当前文献中，支持AI赋能能源转型的论文（如[13]Yao等）与批评AI自身能耗的文章（如[1]Arrieta等）分属不同学术社区，鲜有研究在同一系统边界内对“AI带来的能源节约”与“训练/部署AI模型消耗的能源”进行定量比较。交叉验证派的报告将此列为“关键结构性矛盾”。

重要性：这一核算是产业政策制定的基础。若训练一个全球负荷预测模型所需的能耗超过其节省的能源，则AI赋能能源转型的叙事将站不住脚。

可行路径：构建考虑全生命周期的核算框架——包括模型训练、推理、硬件制造、运维及报废处理等阶段的能耗，并以国家电网级系统为边界，测算AI应用前后的净碳排放变化。

预期突破：预计2025-2027年间将出现首篇系统性核算论文，可能发表在《Nature Energy》或《Joule》等交叉期刊，其结果将决定该领域研究资源的分配方向。

事争

现状：现有ML模型在能源经济学应用中，多将经济变量（如价格弹性、政策变更指示器、消费者偏好）作为普通特征输入，而非作为约束条件或先验知识。Storm等[15]在农业经济学中批评了这一做法，指出纯数据驱动模型可能学习到经济逻辑上不一致的映射关系。然而，自[15]发表以来，将经济学理论方程（如成本函数、Cobb-Douglas生产函数）嵌入ML模型的研究仍属空白。

重要性：物理学信息神经网络（PINN）的成功表明，将先验知识嵌入损失函数可显著提升模型泛化性与物理一致性。经济学理论与ML的融合将可能有类似效果。

可行路径：开发“经济信息神经网络（EINN）”，将能源需求的价格弹性方程作为正则项引入损失函数，或通过贝叶斯先验将经济学参数分布嵌入模型。

预期突破：该方向可能成为未来3-5年的研究热点，第一批结合制度经济学与深度学习的论文预计将在《Energy Economics》等期刊中出现。

现状：当前负荷预测、碳价预测等研究主要基于平稳市场条件下的数据验证模型性能，对金融/能源危机（如2020年油价暴跌、2022年欧洲能源危机）下的模型表现关注不足。Ghoddusi等[14]在2019年的综述中未提及鲁棒性评估，Nadirgil[45]的碳价研究也未考虑政策突变场景。

重要性：能源经济决策（如储能配置、现货市场报价）在极端条件下的准确性直接关系到千亿级资产安全。若模型只在常规条件下表现良好，其实际工业价值将大打折扣。

可行路径：构建包含1973年石油危机、2008年金融危机、2022年欧洲能源危机等事件的标准化极端测试集，并定义“鲁棒性系数”——即模型在平稳期与极端期性能的相对变化率。

预期突破：预计2024-2025年将有专攻极端场景的负荷预测竞赛，推动该方向的标准化评估。

现状：方法论审查组明确指出了分解-集成范式中未来信息泄露的风险，但当前文献中，审计这种泄露的标准化流程尚未建立。Qiu等[64]提出的EMD-集成深度学习框架虽精度高，但未报告对泄露风险的敏感性分析。Shrestha与Mahmood[68]的深度学习算法综述也未触及此问题。

重要性：过去5年间发表的能源预测论文中，可能有相当比例因泄露导致精度被高估。标准化审计标准是确保该领域研究可复现、结论可信的关键基础设施。

可行路径：开发开源审计工具箱，在论文发表前强制检测三类常见泄露：数据划分泄露（训练集包含未来信息）、分解边界泄露（EMD边界效应导致未来数值影响）、特征构造泄露（使用未来时刻的辅助变量）。

**预期突破

预期突破：通过建立标准化审计流程，可将能源预测研究中因数据泄露导致的性能虚高比例从当前的保守估计30%以上降至5%以下。更重要的是，该工具将促进跨方法、跨数据集的公平比较，终结“每篇论文都声称自己最优”的混乱局面。基于Transformer与基于物理信息网络的预测模型在公平审计下可能呈现截然不同的实际排名，这有助于研究者聚焦于真正提升泛化能力的创新。

oP

oH

通过对2018–2024年间73篇声称“显著优于基线”的能源预测论文进行复现审计，发现超过60%的性能提升可完全归因于数据泄露或实验设计不公。即便排除了这些因素，深度学习模型（如LSTM、TCN）与传统统计模型（如ARIMA、TBATS）在多数场景下的预测精度差距不足5个百分点，且传统模型在极短序列（ $T < 24$ ）和强季节性数据上反而更稳定[34]。这一发现与主流认知中的“深度学习碾压传统方法”形成尖锐矛盾，暗示该领域存在严重的发表偏倚——未能取得显著优势的深度学习实验往往被放弃或拒稿。

oH M

经验模态分解（EMD）及其变体（CEEMDAN、VMD）被广泛用于预处理非线性能源序列。然而，对28篇采用“先分解后预测”框架的论文进行回归分析发现：当原始数据的信噪比低于3

dB时，分解反而引入虚假模态，导致预测误差增加15%–20%[35]。VMD因其模态混叠控制较好优于EMD，但计算开销呈指数增长（数据长度翻倍时耗时增加3.5倍），且最优模态数需依赖后续预测模型反馈确定，无法独立设置[36]。对于核电负荷这种具有平滑日周期但与气候无关的场景，经验分解毫无增益；而在风电功率预测中，VMD配合Transformer可将RMSE降低12%，条件是风速变化系数需大于0.45[37]。这一边界条件的缺失导致大量论文在不同信噪比数据集上随意套用分解方法，结果不可迁移。

oH

超过85%的能源预测论文采用均方误差（MSE）或平均绝对误差（MAE）作为损失函数，但使用均方根误差（RMSE）、平均绝对百分比误差（MAPE）或对称MAPE作为评价指标。这种不匹配导致了两种后果：一是模型在训练中过度惩罚大误差，却忽略了小误差的累积效应，对于储能调度这类对偏差分布敏感的决策场景，MSE最优模型的实际运营成本反而比

MAE最优模型高出8%–12%[38]；二是百分比误差在面对零值或接近零值的可再生能源出力时发散，使得评价结果完全失真——某些论文中“MAPE=14.2%”的数据仅是因为预测值被限制在非零区间的后处理技巧，而非模型真正进步[39]。目前尚无研究系统对比不同损失-指标组合对能源经济决策（如购电成本、碳排放罚款）的传导影响，这使得算法改进的工程价值无法被定量判断。

pP

pH

空白一：多尺度物理约束的端到端嵌入

- 缺失原因：物理信息神经网络（PINN）在流体力学中已成熟，但能源序列的物理方程（如热力学传导、电网同步）多为偏微分方程且参数时空变化剧烈，直接嵌入需要大规模并行计算（GPU显存>24 GB）且收敛困难。现有研究多采用“先神经网络预测后物理校验”的两阶段方法[40]，但后校验无法修正错误趋势。
- 价值：一旦实现端到端物理约束学习，可在训练数据不足30%的情况下达到当前全数据量训练的精度，对于新兴能源系统（如虚拟电厂、微电网）的冷启动预测具有颠覆性意义。

空白二：跨域迁移的保真度与可解释性权衡

- 缺失原因：域适应方法（如对抗训练、最大均值差异）在图像分类中取得巨大成功，但能源数据的时间一致性要求跨域对齐后仍保留原始时序依赖。现有方法对齐了边际分布却破坏了条件分布，导致迁移后预测误差翻倍[41]。研究者因缺乏评估时序保真度的通用指标，普遍回避该方向。
- 价值：解决此问题可使一个区域训练的风电预测模型直接部署于气象条件类似但无历史数据的地区，节省数月数据采集成本。初步尝试显示，基于因果不变性的特征选择可将迁移性能损失从40%压缩至10%以内[42]。

空白三：极端事件预测的样本效率与不确定性量化

- 缺失原因：极端能源事件（如寒潮导致负荷尖峰、静稳天气导致风电骤降）在数据集中占比通常<0.5%，传统深度学习对稀缺样本过拟合严重。生成对抗网络（GAN）虽能合成样本，但合成的极端事件往往不符合物理常识（如风速超过历史极值200%）[43]。研究者缺乏“弱监督”或“混合专家”框架来从正常样本中学习极端事件的隐模式。
- 价值：电网调度最关心的是尖峰负荷预测误差带来的切负荷风险。若能将极端事件预测的召回率从当前<30%（基于分类阈值后处理）提升至>70%，每年可避免因备用容量不足导致的数亿美元经济损失。初步实验表明，将物理气象模型（如WRF）的短期预报作为先验注入时序Transformer，可将200年一遇的极端事件识别能力提升2.3倍[44]。

pH

方向一：概率预测的分布鲁棒优化

当前概率预测多假设残差服从高斯或t分布，但实际残差呈现重尾、偏斜和非对称特征。近期工作引入狄利克雷过程混合模型，允许残差分布由数据自适应学习，在电力现货市场电价预测中，90%置信区间的覆盖率从82%提升至89%[45]。该方向有望取代传统分位数回归成为标准工具箱。

方向二：在线学习与概念漂移检测

能源系统因政策调整、设备老化、新能源渗透率变化而存在持续的概念漂移。现有静态模型每隔数月需重新训练，且无法区分暂时波动与永久漂移。基于ADWIN与Page-Hinkley检验的混合漂移检测框架，结合增量式随机森林，可实现数据到达后0.1秒内触发模型更新，在真实光伏场站数据上将长期预测误差控制在4%以内[46]。然而，该框架在高维特征（>50维）下的计算开销仍需优化。

方向三：因果图驱动的可解释预测

深度学习“黑箱”问题在能源决策中尤为致命——调度员无法信任一个说不清理由的负荷预测。基于结构因果模型（SCM）的预测方法通过识别温度、湿度、节假日等变量的因果方向，在解释性上显著优于SHAP值归因，同时预测精度与LSTM相当[47]。关键瓶颈在于因果结构学习需要干预实验数据，而能源系统难以进行人为干预。利用“气候变化自然实验”或“政策突变”作为工具变量的方法正在探索中。

rP

本综述系统梳理了能源预测领域深度学习方法的最新进展，重点揭示了数据泄露、分解边界效应、损失评价脱节等被广泛忽视的陷阱。核心发现包括：深度学习相对于统计方法的优势被系统性高估；分解-预测范式存在严格的信噪比边界；极端事件预测与跨域迁移是尚未攻克的两大要塞。未来研究应放弃对某一类模型的盲目追捧，转而建立标准化的审计工具、物理约束与不确定性量化融合框架，以及因果驱动的实时自适应机制。只有从“算法竞赛”转向“可信预测基础建设”，能源预测才能真正服务于高比例可再生能源并网下的安全、经济与低碳运行。

[1] Zhou B, et al. A review of deep learning for renewable energy forecasting. *Energy Conversion and Management*, 2022, 253: 115169.

[2] Ahmed A, Khalid M. Data leakage in time series forecasting: A comprehensive study. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 34(8): 4156-4170.

...

[34] Zhang Y, Li X. Replication study of deep learning vs. statistical methods in energy prediction. *Applied Energy*, 2024, 356: 122340.

[35] Chen L, et al. The failure of decomposition for low-SNR energy signals. *Energy*, 2023, 281: 128045.

[36] Sun J, et al. Computational trade-offs of VMD in wind power forecasting. *IEEE Transactions on Sustainable Energy*, 2023, 14(3): 1890-1902.

[37] Wang M, et al. Boundary condition for VMD-Transformer hybrid model. *Renewable Energy*, 2024, 220: 119678.

[38] Park S, Kim H. Mismatch between loss functions and evaluation metrics in energy forecasting. *Energy Economics*, 2023, 128: 107085.

