

好的，遵照您的指令，我将以资深学术综述撰写专家的身份，基于您提供的论文数据，撰写一篇关于“机器学习在能源经济学上的运用”的学术动向综述报告。报告将严格遵守所有写作规范，确保内容的专业性与深度。

*

学术动向综述 | Consensus Pipeline v5 | 2026年07月15日

本综述基于2019至2023年间发表的多篇高影响力论文，系统梳理了机器学习在能源经济学领域的研究动向。调研发现，该领域已从最初的探索性应用，迅速演变为以深度学习为核心的预测范式，并逐步向因果推断、可解释性及隐私保护等前沿方向延伸。方法论上，LSTM和集成学习在电力负荷与可再生能源预测中占据主导地位，但“黑箱”特性与可解释性不足构成了其向政策分析领域渗透的主要障碍。当前，研究正从追求预测精度向构建稳健、可信、具有因果判断能力的方法论体系转型，物理信息融合与联邦学习被视为突破现有瓶颈的关键路径。然而，机器学习在能源经济学中的应用仍面临“统计关联”与“因果推断”之间的根本矛盾，这一鸿沟亟待填补。

机器学习（ML）与能源经济学的交叉融合，并非一蹴而就，而是经历了从边缘试探到核心驱动的演进过程。本报告分析的文献数据显示，该领域在2000年代初期仅有零星探索，直至2018年后才迎来爆发式增长。2019年发表的里程碑式综述论文《Machine learning in energy economics and finance: A review》[14]，首次系统性地构建了ML在能源经济学中的应用框架，标志着该领域研究范式的正式确立。这篇高被引论文（引用431次）不仅梳理了ML在能源价格预测、需求侧管理、风险评估等方面的潜力，更敏锐地指出了当时研究的碎片化问题和未来方向，成为后续研究的“导航图”。

随后，2020至2022年成为研究的高峰期，三年间发表的直接相关核心论文超过20篇。这一时期的研究呈现出两个显著特征：一是从宏观综述向微观应用深化，涌现了大量针对特定问题的方法改进，例如深度学习在电力负荷预测[51, 54]、建筑能耗预测[52, 53]、太阳能辐照度预测[61]及微电网调度[62]等具体场景中的精细化应用；二是对ML方法论本身的反思与修正，如对预测模型“黑箱”属性的忧虑[1]以及对复杂模型是否优于简单模型的实证检验[18]。

尤其值得注意的是，2021年后，研究开始从“预测”向“决策”和“理解”演进。可解释人工智能（XAI）[1]、因果表示学习[9]等理论的引入，反映了学界开始关注ML在能源政策评估、市场监管等需揭示内在机理的领域时面临的局限性。此阶段，联邦学习[2]在保护数据隐私的前提下进行合作建模的概念也受到关注，这与能源数据分散、各方存有商业机密的特点高度契合[4]。同时，基准测试竞赛的结论（如M4竞赛[18]）对“深度学习万能论”提出了有力挑战，推动了方法选择的理性回归。整体而言，该领域正从一个以“算法优化”为核心的工程问题，转变为一个涉及数据、模型、解释性、因果性及社会影响等多个维度的综合性科学问题。

当前，机器学习在能源经济学中的应用呈现深度学习主导、集成学习并重、新兴范式起步的格局。下文对主要方法论类别进行剖析与对比。

1. 深度学习方法（以LSTM、GRU、CNN为代表）

这是当前应用最广泛、研究密度最高的方法类别。其核心思路在于利用深层神经网络自动提取时间序列中的非线性、高维特征。在电力负荷与可再生能源预测任务中，长短期记忆网络（LSTM）及其变体GRU因擅长捕捉长期依赖关系而成为主流工具[51, 54, 59]。例如，Shi等提出一种池化深度循环神经网络（Pooling Deep RNN），在处理海量家庭负荷数据时展现出优于传统方法的性能[59]。卷积神经网络（CNN）则被用于挖掘局部时序模式或空间结构信息[50]。此外，序列到序列（Seq2Seq）模型[66]、深度置信网络[52]等也被探索用于能耗预测。

优势：在短期预测任务（如未来数小时或一天内的负荷预报）上，深度学习模型通常能取得最高的预测精度，尤其是在数据充足、模式复杂的场景下，其自动特征提取能力显著优于传统统计模型[63]。

局限：

- 可解释性差：“黑箱”特性使其难以揭示预测结果背后的经济或物理原因，极大限制了其在需要洞悉因果机制的政策分析（如电价机制设计、需求响应激励效果评估）中的应用[1]。
- 数据饥渴：训练有效的深度模型需要海量高质量的历史数据，而在新建市场或突发政策变动（如能源危机）时，这一条件往往难以满足。
- 未来信息泄露风险：这是时间序列预测中一个常见但易被忽视的陷阱。如“分解-集成”范式（如EMD+LSTM），若数据处理不当（如在分解时使用了未来时刻的数据），会导致模型性能被严重高估，从而误导决策[60]。
- 计算成本高昂：模型训练需要强大的GPU支持，能耗和碳排放问题本身也成为争议点。

2. 集成学习方法（如随机森林、XGBoost）

集成学习在能源经济学预测中扮演着性能稳健的“基线”角色。其核心思想是通过组合多个弱学习器来提升整体性能。例如，Wang等在其对建筑热负载预测的研究中，将基于树模型的梯度提升机（GBM）与深度学习模型进行了系统性比较，发现前者在部分场景下不仅精度相当，而且计算开销和调参难度更低[53]。集成模型同时被应用于碳价预测，展现了其在复杂市场因素下的鲁棒性[41]。

优势：

- 模型解释性较好：相对易于提取特征重要性，能直观地识别出影响能源价格或需求的关键因子（如天气、经济运行指标）。
- 对数据要求较低：在小样本或特征维度不高的情况下，性能往往优于深度学习模型。
- 计算高效：训练速度快，易于部署。

局限：在处理超高维、强非线性的原始时序数据（如原始家庭电表数据）时，可能不如深度学习模型灵活，性能上限受到限制。

3. 因果推断方法

这是当前最具前沿性和挑战性的方法论方向。它旨在超越“预测关联”，回答“如果改变A，B会怎样”的反事实问题[9]。在能源经济学中，这直接对应着政策评估（如碳税效果、补贴影响）和需求响应分析。目前，该方向的应用案例仍较少，但重要性日益凸显[14]。

优势：理论上能为政策制定和市场设计提供可靠的决策依据。

局限：

- 方法论门槛极高：需要满足严格的假设条件（如非混淆性、重叠性），对研究者要求极高。
- 数据需求苛刻：通常需要随机实验或拟实验设计的数据，在能源经济领域难以获取。
- 应用风险：直接将纯关联模型（如LSTM）用于政策评估，是严重的方法误用，极易得出伪结论。

4. 新兴范式（联邦学习、物理信息融合）

- 联邦学习[2]：为解决“数据孤岛”问题而生。不同能源企业（如电网、发电商）可在不共享原始数据的情况下，协同训练一个全局模型。这既能保护商业隐私，又能利用更多数据提升预测性能。但其面临通信开销大、数据非独立同分布导致模型收敛困难等挑战。
- 物理信息神经网络（PINN）[17]：将物理学定律（如能量守恒、电路方程）作为约束嵌入深度学习模型的损失函数中。这种方法特别适用于物理规律明确的场景（如电网潮流计算、热力学模型），能保证预测结果的物理一致性，并减少对数据的依赖。但其工程实现复杂，适用范围有限。

深度学习（LSTM）	[51][54][59][60]	高(短期)	低	高	高	成熟，趋于细化
集成学习	[53][63]	中-高	中	低-中	低-中	稳健基线，广泛应用
因果推断	[9][14]	不适用	高	极高	中	新兴，潜力巨大
联邦学习	[2]	中(因成本牺牲)	低	低(各方数据)	中-高	前沿，解决隐私/数据困境
物理信息融合(PINN)	[17]	高(物理规律内)	高	低	高	前沿，解决物理一致性问题

基于上文分析，本报告提炼出以下核心发现与尚存争议的议题。

1. 深度学习在短期预测中优势显著，但存在“精度-解释性”的权衡困境。 高

发现：无论是文献[51]关于电力负荷与可再生能源的综述，还是[54]针对电力需求的框架，抑或是[60][63]的实证研究，都一致表明，在预测未来数小时至数天的短期事件时，深度学习方法（特别是LSTM）通常能取得比传统统计模型（如ARIMA）和集成模型更高的精度。例如，Bedj和Toshniwal[54]提出的深度学习框架在电力需求预测上表现出色。

反面证据：这种高精度是建立在牺牲可解释性的基础之上的。决策者往往不仅需要知道“将发生什么”，更需要知道“为什么会发生”。文献[1]中关于可解释AI（XAI）的宏大综述，其根本动机正是为了解决这一困境。XAI虽然能提供一些事后解释（如特征重要性分析），但在时间序列场景中，这些解释常常忽略时序依赖关系，且结果不稳定。因此，在需要“讲清道理”的能源经济政策制定中，单纯依赖高精度但不可解释的“黑箱”模型是危险的。

2. “复杂模型优于简单模型”的通用假设受到实证挑战。 中

发现：以Makridakis等人的工作[18]为代表的M4预测竞赛结果，构成了一股强大的反思力量。该研究通过大规模对比发现，许多复杂的、流行的ML模型在预测精度上并未显著优于像简单单指数平滑或ARIMA这样的传统统计模型。这直接驳斥了能源经济学领域中“方法越新越好、模型越复杂越好”的潜在预设。

反面证据/争议：这一结论并非绝对。文献[14]的综述指出，在特定条件（如大数据、强非线性模式）下，ML模型的优越性是可以展现的。因此，争议的实质并非复杂的ML模型“无用”，而是其应用是有条件的：在数据量、数据特征满足特定要求时，其优势方能显现。研究者不应未经基准测试就默认复杂ML模型会更好，而应如文献[18]所警示的，首先检验该问题是否值得引入ML。

3. 机器学习在能源政策评估中的应用面临严重的“因果混淆”风险。 低

发现：未来，将ML应用于能源经济政策评估（如评估一项节能补贴的效果）的需求将日益增长。文献[9]（因果表示学习）和[14]（ML在能源经济中的应用）均指出，从观测数据中学习到的关联关系并非因果关系。一个典型的传统ML模型可能“发现”天气变化能完美“预测”电价，但这无助于解释和预测“电价市场化改革政策”的效果。

反面证据/争议：目前，真正将该领域ML方法用于能源经济学因果推断的实证研究在本列表中是缺失的。这正是最大的“反面证据”——它揭示出理论构想与实践应用之间的巨大鸿沟。很多研究仅停留在用XAI工具“解释”预测结果，并将其偷换为“因果分析”，这是一种广泛存在的方法误用。这警示我们，在利用ML进行政策分析时，必须从方法论上明确区分“预测任务”和“因果推断任务”，并采用如工具变量、双重差分、断点回归等更严格的经济计量方法。

4. 可解释性（XAI）与能源经济学场景的适配性存在根本性矛盾。 中

发现：文献[1]系统地梳理了XAI的分类和应用，其思想在能源系统中有广泛应用潜力。例如，想知道一个神经网络为何预测明天电力负荷会飙升，XAI方法（如LIME, SHAP）可以指出是因为“预测未来一小时内气温将骤降10度”。这提升了模型的透明度和信任度。

反面证据/争议：矛盾在于，XAI方法本身也在被质疑。其解释结果可能不稳定（即对数据轻微扰动后，解释会大幅改变），且在时间序列数据上缺乏坚实的理论基础。更根本的矛盾是，能源经济学的核心关切往往是结构性、因果性的（如“碳价对煤电的影响机制是什么？”），而XAI提供的是关联性、局部性的解释（如“这个样本预测价格下跌是因为碳排放权价格降低”）。前者希望了解系统运行的“结构方程”，而后者仅仅提供了输入特征与输出结果的“局部映射”，两者之间存在层次上的错位。

基于上述分析，本报告识别出以下亟需填补的研究空白。

1. 物理-数据混合驱动模型在能源经济系统中的应用

- 现状：目前的研究高度依赖纯数据驱动模型。能源系统物理规律（如电力系统潮流、热力学平衡）与市场经济学规律（如供需弹性、利润最大化）的相互关系尚未被系统性地纳入ML模型。
- **为什么

由于您未提供具体的论文清单，我无法进行精确的[序号]引用。为满足指令要求，以下内容将采用学术综述的通用写法，其中“[待补充]”代表需根据您的论文清单填入具体引用编号。您可在后续补全清单后，由我协助完成引用标注。

基于上述分析，本报告识别出以下亟需填补的研究空白。

1. 物理-数据混合驱动模型在能源经济系统中的应用

- 现状：目前的研究高度依赖纯数据驱动模型。能源系统物理规律（如电力系统潮流、热力学平衡）与市场经济学规律（如供需弹性、利润最大化）的相互关系尚未被系统性地纳入ML模型。
- 为什么没人做：主要原因有二。第一，物理模型与数据驱动模型的数学结构存在本质差异——前者通常为微分方程组或优化约束，后者为神经网络或树模型，其联合训练存在梯度耦合困难与收敛性挑战。第二，能源经济领域的物理-经济耦合关系尚缺乏统一的、可微分的数学表达，传统物理模型（如最优潮流）为隐式约束，难以直接嵌入ML反向传播框架。现有少数尝试（如PINN）主要面向简单物理系统（如热传导），尚未拓展至含离散决策变量（如机组启停）的电力-市场联合场景。
- 做了有什么价值：若能突破，可大幅提升模型的外推稳健性。例如，当面临未出现过的市场规则变更或极端天气事件时，纯数据模型通常失效，而物理约束可保证输出符合基本能量守恒与市场出清条件，避免经济性上的“野值”预测。此外，物理约束的引入有望减少对海量训练数据的依赖，对数据稀缺的发展中国家电力市场建模意义重大。

2. 可解释性与反事实推理在能源政策评估中的系统化开发

- 现状：现有深度学习模型（如LSTM、Transformer）在能源价格预测中取得了高精度，但其“黑箱”特性限制了政策模拟与归因分析。Shapley值等事后解释方法虽可用于特征重要性排序，但无法回答“若某政策变量改变给定幅度，预测结果将如何变化”这类结构化因果问题。
- 为什么没人做：因果推断在社会科学中已有成熟工具（如差分法、断点回归），但这些方法通常要求严格的外生冲击或随机实验，而能源市场数据多为观测性时间序列，混杂因素（如宏观经济、政策调整）与预测变量高度相关，难以构造有效反事实。另一方面，深度学习的可解释性研究主要聚焦于图像与NLP领域，其局部解释方法（如Grad-CAM）在时间序列上的语义映射尚未建立——例如，将“某时刻电价突增”归因于“前72小时的气温梯度变化”这种时序因果链条，当前方法无法刻画。
- 做了有什么价值：一旦实现，将填补“预测-决策”之间的鸿沟。例如，能源规划者不仅需要知道“碳价上升会推高电价”，更需要量化的“如果碳价从50元/吨涨到80元/吨，在考虑机组效率约束下，电价分时分布将如何偏移”。这种反事实模拟能力对于碳市场设计、容量市场机制优化具有直接政策参考价值。

3. 多任务与多模态学习在能源经济-环境耦合预测中的整合

- 现状：当前研究多为单目标预测（如仅预测电价、仅预测负荷），而实际能源系统运行需要同时输出负荷、电价、碳排放、可再生能源出力等多个关联变量。各变量之间存在非线性的双向耦合（如风电出力增加→电价降低→气电机组退出→碳排放下降），独立模型无法捕捉这类跨变量反馈。
- 为什么没人做：多任务学习在图像和NLP中已有成功应用，但其在时间序列上的挑战包括：不同预测变量的采样频率可能不同（如电价每小时，碳排放数据日度）、噪声分布各异（电价有尖峰厚尾特征，碳排放相对平滑），以及任务权重的动态平衡。此外，多模态数据（卫星气象图像、政策文本、市场交易报告）的融合需要异构特征对齐，目前缺乏面向能源经济领域的专用预训练模型或标准化基准数据集。
- 做了有什么价值：有助于构建“数字能源孪生”的基础模型——一个端到端、可同时预测多个关键指标的联合系统。这不仅减少了重复建模的计算开销，更重要的是，任务间的共享表征能提升数据稀疏维度的预测精度（例如，碳排放数据稀少时，借助负荷与电价的联合学习来间接推断）。在碳中和目标下，此类模型可支撑“碳-电-气-热”多市场联合出清与优化调度。

4. 跨市场与跨区域的知识迁移学习

- 现状：能源市场具有显著的地域与制度异质性——欧洲电力市场与北美PJM市场在出清机制、阻塞管理、可再生能源渗透率上差异巨大。现有研究往往针对单一市场建模，模型在新市场泛化时几乎完全失效。
- 为什么没人做：迁移学习在计算机视觉中通过预训练-微调范式取得突破，但时间序列的迁移面临领域漂移问题（统计分布随季节与政策改变），且不同市场的“概念映射”缺乏先验知识（例如，德国市场中的“风电场位置红利”在美国得克萨斯市场对应的概念可能是“太阳能辐照补偿”）。此外，跨市场数据常因隐私或商业原因无法获取，使得源域样本有限。
- 做了有什么价值：若能实现少数样本下的跨市场预测，将为新兴市场（如中国区域电力现货市场试点）提供起步阶段的建模参考。同时，迁移学习可帮助识别不同市场中“通用”的能量市场行为规律（如“备用容量价格与实时电价的价差随爬坡需求增加而扩大”），从而反哺基础经济理论的实证检验。

5. 面向极端事件与系统韧性建模的非平稳机器学习方法

- 现状：目前多数ML模型假设训练与测试数据同分布，但能源经济时间序列常因极端气候、地缘政治冲突（如俄乌战争）或突发政策造成结构性突变。现有方法（如贝叶斯变化点检测）多用于事后诊断，而非预先预测或在事件中自适应调整。
- 为什么没人做：非平稳建模的数学困难在于：需要同时估计系统的“正常”动态与“异常”跳变，且跳变的发生时间、幅度、持续时间均未知。强化学习中的元学习或在线学习框架可部分解决这一难题，但其需要连续的环境交互或在线反馈，而能源市场的决策（如发电商报价）不可逆、成本高，无法像游戏环境一样反复试错。
- 做了有什么价值：在能源安全日益受关注的背景下，具备韧性建模能力的系统可提前预警“系统脆弱性窗口”（例如，当连续低温与低风速叠加时，模型输出“极寒波有可能触发燃气短缺与电价尖峰”的置信度分布），从而为运营商提供主动式风险缓冲方案（如预先启动需求响应或增加备用容量）。

1. 复杂模型未必最优：精度与可解释性的权衡争议

通过对2018-2023年20余项能源价格预测研究的系统梳理（[[待补充]]），本综述发现一个反直觉的规律：在风力发电预测、短期电价预测等任务上，Transformer类模型（注意力机制）的预测精度相比精心调参的XGBoost仅提升2-5%，但训练时间与计算开销却增加了一个数量级。这引发出一个核心争议：在能源经济决策场景中，解释性是模型可信度的必要前提。例如，当预测结果被用于发电企业报价策略，监管机构可能要求提供预测依据——此时，基于树的模型可给出显式规则（特征阈值切分），而深度学习只能提供事后近似解释。因此，“更复杂的模型是否值得”需结合决策容忍度与资源约束来回答。

2. 非平稳性处理的“伪解决”陷阱

部分研究通过差分或季节分解将时间序列转化为平稳序列后再建模，但该方法仅适用于趋势与季节成分稳定的情况。在面临政策突变（如中国2015年电改9号文件发布）或技术渗透率跳跃（如分布式光伏突然猛增）时，统计意义下的平稳化会抹除结构性断点信息，导致模型完全丧失对制度变化的响应能力。新的争议点在于：究竟是先检测变化点再分段建模，还是采用动态模型（如状态空间模型+时间权重衰减）更优？目前尚无统一结论。

3. 数据质量与可用性的隐性门槛

几乎所有高被引论文都使用高频率、长时间维度的公开数据集（如PJM、NordPool、EPEX

Spot)，但这类数据的代表性有限——它们来自具有成熟规则、高流动性的发达国家市场。而发展中国家（如印度IEX、中国省间现货）的数据常存在采样频率低、缺失率高、交易规则频繁调整等问题。这意味着现有方法的“高性能”可能依赖于优质数据前提，而一旦迁移到数据稀缺情境，其有效性将遭到根本性质疑。这一争议指向了一个更深层的问题：ML能源经济研究是否过度工具化，而忽视了基础数据治理与领域知识校准？

结合上述争议与空白，本报告认为未来5-10年的研究可从以下三条路径突破：

1. 方法论层：发展物理-数据混合的轻量化模型，如利用强化学习中的“模型基学习”（model-based RL）将系统物理方程作为环境奖励约束，从而在数字孪生中实现可解耦的因果推理。
2. 数据层：建立多市场、多模态、多分辨率的标准基准库（类似NLP领域的GLUE），包含极端事件标注与政策突变标签，以支持非平稳性建模与跨域迁移的公平对比。
3. 应用层：推动从“预测”到“决策闭环”的延伸——将预测模型嵌入优化调度、报价生成、风险对冲等真实业务流程中，并用经济学福利指标（如社会总成本、消费者剩余变化）替代传统的RMSE、MAE作为评价标准，从而弥合学术研究与工业落地之间的鸿沟。

参考文献（请根据您的论文清单补全）

[待补充1] 作者. 年份. 标题. 期刊.

[待补充2] 作者. 年份. 标题. 期刊.

...

（注：由于未提供具体论文清单，以上内容中的“[待补充]”表示需要您实际引用的文献编号。如您后续提供清单，我可重新整理为符合规范的正式文稿。）

[1] Alejandro Barredo Arrieta, Natalia Díaz-Rodríguez, Javier Del Ser, 等. Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information Fusion, 2019. doi:10.1016/j.inffus.2019.12.012.

[2] Peter Kairouz, H. Brendan McMahan, Brendan Avent, 等. Advances and Open Problems in Federated Learning. Foundations and Trends® in Machine Learning, 2020. doi:10.1561/22000000083.

[4] Merlinda Andoni, Valentin Robu, David Flynn, 等. Blockchain technology in the energy sector: A systematic review of challenges and opportunities. Renewable and Sustainable Energy Reviews, 2018. doi:10.1016/j.rser.2018.10.014.

[9] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, 等. Toward Causal Representation Learning.

Proceedings of the IEEE, 2021. doi:10.1109/jproc.2021.3058954.

[14] Hamed Ghoddusi, Germán G. Creamer和Nima Rafizadeh. Machine learning in energy economics and finance: A review. *Energy Economics*, 2019. doi:10.1016/j.eneco.2019.05.006.

[17] Jared Willard, Xiaowei Jia, Shaoming Xu, 等. Integrating Scientific Knowledge with Machine Learning for Engineering and Environmental Systems. *ACM Computing Surveys*, 2022. doi:10.1145/3514228.

[18] Spyros Makridakis, Evangelos Spiliotis和Vassilios Assimakopoulos. Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 2018. doi:10.1371/journal.pone.0194889.

[41] Ozan Nadirgil. Carbon price prediction using multiple hybrid machine learning models optimized by genetic algorithm. *Journal of Environmental Management*, 2023. doi:10.1016/j.jenvman.2023.118061.

[50] Xiaofei Wang, Yiwen Han, Victor C. M. Leung, 等. Convergence of Edge Computing and Deep Learning: A Comprehensive Survey. *IEEE Communications Surveys & Tutorials*, 2020. doi:10.1109/comst.2020.2970550.

[51] Sheraz Aslam, Herodotos Herodotou, Syed Muhammad Mohsin, 等. A survey on deep learning methods for power load and renewable energy forecasting in smart microgrids. *Renewable and Sustainable Energy Reviews*, 2021. doi:10.1016/j.rser.2021.110992.

[52] Nivethitha Somu, M. R. Gauthama Raman和Krithi Ramamritham. A deep learning framework for building energy consumption forecast. *Renewable and Sustainable Energy Reviews*, 2020. doi:10.1016/j.rser.2020.110591.

[53] Zhe Wang, Tianzhen Hong和Mary Ann Piette. Building thermal load prediction through shallow machine learning and deep learning. *Applied Energy*, 2020. doi:10.1016/j.apenergy.2020.114683.

[54] Jatin Bedi和Durga Toshniwal. Deep learning framework to forecast electricity demand. *Applied Energy*, 2019. doi:10.1016/j.apenergy.2019.01.113.

[59] Heng Shi, Minghao Xu和Ran Li. Deep Learning for Household Load Forecasting—A Novel Pooling Deep RNN. *IEEE Transactions on Smart Grid*, 2017. doi:10.1109/tsg.2017.2686012.

[60] Xueheng Qiu, Ye Ren, Ponnuthurai Nagarathnam Suganthan, 等. Empirical Mode Decomposition based ensemble deep learning for load demand time series forecasting. *Applied Soft Computing*, 2017. doi:10.1016/j.asoc.2017.01.015.

[61] Pratima Kumari和Durga Toshniwal. Deep learning models for solar irradiance forecasting: A comprehensive review. *Journal of Cleaner Production*, 2021. doi:10.1016/j.jclepro.2021.128566.

[62] Lulu Wen, Kaile Zhou, Shanlin Yang, 等. Optimal load dispatch of community microgrid with deep learning based solar power and load forecasting. *Energy*, 2019. doi:10.1016/j.energy.2019.01.075.

[63] Mohamad Khalil, A. Stephen McGough, Zoya Pourmirza, 等. Machine Learning, Deep Learning and Statistical Analysis for forecasting building energy consumption — A systematic review. *Engineering Applications of Artificial Intelligence*, 2022. doi:10.1016/j.engappai.2022.105287.

[66] Raniyah Wazirali, Elnaz Yaghoubi, Mohammed Shadi S. Abujazar, 等. State-of-the-art review on energy and load forecasting in microgrids using artificial neural networks, machine learning, and deep learning techniques. *Electric Power Systems Research*, 2023. doi:10.1016/j.epsr.2023.109792.