

本综述基于67篇高质量文献，系统梳理机器学习在能源经济学中的演进脉络和方法论格局。研究发现，该领域经历了从2018年前的探索期到2020年后的爆发式增长，研究方法从传统统计模型向深度学习、强化学习、因果推断等多元化技术路径演进。核心发现包括：深度学习在能源价格与负荷预测中的精度优势具有边界条件，在小样本或政策突变场景下统计模型可能更具稳健性；可解释人工智能（XAI）和因果推断方法正成为提升模型可信度的关键路径；联邦学习与区块链技术为分布式能源市场的数据协作与隐私保护提供了解决方案。当前领域存在五大研究空白：跨市场碳价预测的迁移学习框架缺失、物理信息融合方法的规模化应用瓶颈、标准化基准测试的匮乏、多能源系统耦合预测的理论薄弱、以及气候政策冲击下模型泛化能力的系统性评估不足。本报告提出，未来研究应聚焦于发展具有因果解释力和物理约束的混合预测模型，建立跨场景、跨尺度的统一评估体系。

机器学习在能源经济学中的应用研究可追溯至21世纪初，但其系统化发展始于2018年前后。从年份分布来看（参见数据部分），2003-2017年间年均发文量仅1-2篇，呈现出零星探索的特征。这一时期代表性的工作包括Armaroli和Balzani（2006）对能源供应挑战与机遇的前瞻性分析[参见[6]]。

2018-2020年是该领域方法论突破的关键转折期。短短三年间，年发文量从2篇激增至9篇，并涌现出一批标志性方法论综述。Ghoddusi等人（2019）发表的《Machine learning in energy economics and finance: A review》[14]首次系统梳理了机器学习在能源价格预测、风险管理和投资组合优化中的应用地图，引用量已达431次，成为该交叉领域的核心知识入口。同年，Barredo Arrieta等人（2019）的《Explainable Artificial Intelligence (XAI)》[1]以9162次引用奠定了可解释人工智能的概念与分类学框架，对能源经济学中的模型可信度问题产生了深远影响。

2021-2023年进入方法论爆发与跨学科融合的鼎盛期，年均发文量达8-11篇。这一时期的关键特征包括：深度学习架构（LSTM、CNN、Transformer）大量涌现，如Shi等人（2017）提出的Pooling Deep RNN参见[60]；同时，因果推断与表示学习的引入表明方法论从“相关性预测”向“因果理解”的范式转变[9]；联邦学习[2]和区块链技术[4]的引入则标志着数据隐私与分布式治理成为新的研究维度。特别值得注意的是，Antonopoulos等人（2020）的《AI and machine learning approaches to energy demand-side response》[12]和Kaack等人（2022）的《Tackling Climate参见[23]]。

![年度发文量趋势](charts/year\_trend.png)

图1：年度发文量趋势（红色柱体为高活跃年份）

![方法论分布](charts/method\_distribution.png)

图2：方法论占比分布

![期刊等级分布](charts/grade\_distribution.png)

图3：期刊等级分布（S级=顶刊，A级=优秀，B级=良好）

当前机器学习在能源经济学中的研究方法可归纳为六大类别，各具技术特征与应用边界。

## NM 与五严I、争代r中中

这类方法以处理时间序列数据的非线性、长依赖关系见长。Shi等人（2017）的Pooling Deep RNN参见[60]。Bedi和Toshniwal（2019）提出的深度学习电力需求预参见[52]。然而，其在稀疏或噪声数据环境下的过拟合风险不可忽视。参见[53]。

## NG

参见[57]。XGBoost和随机森林被广泛应用于碳价和电价预测中的特征选择与基线建模，其优势在于对高维、异构特征的鲁棒性和内置的变量重要性机制。

## NP

François-Lavet等人（2018）的《An Introduction to Deep Reinforcement Learning》[7]为能源经济学引入序贯决策框架。该方法在需求响应、定价策略和电网调度等需要“预测-决策”闭环的场景中展现潜力，但其对状态-动作空间的维数依赖限制了在大规模市场模拟中的应用。

## NR

Schölkopf等人（2021）的《Toward Causal Representation Learning》[9]代表了方法论的根本性转向。传统机器学习基于相关性推断，而因果表示学习试图识别变量间的因果结构。在碳价预测中，这有助于区分政策冲击与市场机制对价格波动的驱动效应。

## NS

Kairouz等人（2020）的联邦学习综述[2]提出了解决数据孤岛问题的分布式训练框架。在能源市场中，不同区域或公司的敏感数据（如用户负荷曲线、交易记录）难以集中共享，联邦学习在不泄露原始数据的前提下训练统一模型，契合了欧盟GDPR等监管要求。

## NT 之盟器器参发匿击减严与

参见[17]。在能源系统预测中，这表现为将热力学方程、能量守恒定律作为模型约束，显著提升了外推条件下的预测稳健性。

|  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|

参见[60]

参见[60]

|      |     |        |   |     |   |      |
|------|-----|--------|---|-----|---|------|
|      | 体信  |        |   |     |   |      |
| 因果推断 | [9] | 推理精度高  | 高 | 中   | 高 | 新兴方向 |
| 联邦学习 | [2] | 隐私保护下中 | 低 | 分布式 | 高 | 关键需求 |

参见[17]

M

支持证据：Shi等人（2017）的Pooling Deep RNN在家庭负荷预测中相较于传统统计模型显著降低了均方根误差[59]；Bedi和Toshniwal（2019）的深度学习框架在电力需求预测中亦取得突破性进展[54]。

反面证据：Makridakis等人（2018）的《Statistical and Machine Learning forecasting methods: Concerns and ways forward》[18]以1407次引用警示学界——ML方法在小样本（<1000条）或存在结构性突变（如政策改革）的数据中表现往往不及经过充分调优的简单统计模型。参见[63]。

置信度：高

N

支持证据：Barredo Arrieta等人（2019）提出的XAI概念框架[1]将可解释性定义为高风险决策场景的准入条件。在碳市场交易和能源监管中，模型需要提供“为何做出此预测”的因果解释。

反面证据：复杂深度学习模型（如深度集成学习）即便应用了显著性映射等解释工具，特征重要性的不稳定性问题依然突出。当面对多变量耦合、具有滞后效应的环境系统时，XAI可能将相关关系误证为因果关系。

置信度：高

P C

\*\*支持参见[60]。参见[57]。

反面证据：当基础预测模型（如Transformer、LSTM）已具备充分的非线性表达能力时，分解策略带来的误差累积和模

态混叠问题可能导致精度不升反降。参见[17]。

置信度：中

## R

支持证据：Kairouz等人（2020）的联邦学习综述[2]强调其在隐私保护框架下的分布式训练能力。Andoni等人（2018）的区块链技术在能源部门的系统综述[4]进一步提出了去中心化信任机制。

反面证据：不同地区的用户负荷模式、政策环境、经济结构数据具有严重的非独立同分布特性，这会导致联邦聚合模型性能衰减。参见[41]。

置信度：中

## S

支持证据：Schölkopf等人（2021）的因果表示学习框架[9]为识别能源市场的因果结构提供了理论工具。在碳价预测中，理解“政策冲击→市场预期→价格传导”的因果链条具有显著的策略意义。

反面证据：当前研究多止步于理论展望。参见[41]。本综述所审查的论文列表中，无一篇提供因果推断在能源预测中的实证案例。

置信度：低——现状清楚，但缺乏实证

## M

现状：现有碳价预测研究多为单一区域（如欧盟EU ETS、中国全国碳市场）建模，缺乏跨市场知识迁移的系统方法论。

为什么没人做：不同碳市场的配额分配、价格调节机制、产业结构和减排目标存在根本性差异，简单的迁移学习容易产生负迁移效应。

做了有什么价值：若成功开发跨市场迁移框架，可在新兴市场数据积累不足时快速建立预测基线，缩短政策学习曲线。

可行路径：结参见[52]。

## N

参见[17]。

为什么没人做：将离散的、多尺度的物理规律（如叶片光合作用、全球碳收支）嵌入统一的神经网络框架面临技术挑战。现有物理信息损失函数方法在低维问题上有效，在高维、跨尺度问题中收敛困难。

做了有什么价值：成功的物理信息融合可显著提升模型在外推条件下的预测稳健性，尤其是在捕捉能源价格对极端气候事件的非线性响应方面。

## P

现状：Makridakis等人（2018）[18]的呼吁在能源经济学预测领域仍未得到系统性响应。不同研究使用私有数据集、不同预处理流水线和评估指标，使得方法论对比难以进行。

为什么没人做：能源数据涉及商业机密和政策敏感性（如交易记录、用户负荷），公开数据集构建面临隐私合规障碍。

做了有什么价值：建立类似M3/M4竞赛的标准化基准，可有效区分不同方法的真实优势与适用边界。

## R

现状：电力、天然气、碳市场间存在强耦合关系，现有研究多孤立建模。Staffell等人（2018）[3]对氢能系统的前瞻性分析揭示了多能源耦合的复杂互动。

为什么没人做：多系统耦合建模需要跨学科团队（能源工程、经济学、控制理论）协作，且数据采集成本极高。

做了有什么价值：耦合预测模型可系统评估政策干预（如碳税、可再生能源补贴）在跨市场间的传导效应。

## S

参见[8]动态博弈。现有预测模型缺乏对极端政策冲击（如碳价大幅飙升）的鲁棒性测试。

为什么没人做：历史数据中缺乏类似干预的样本，模型在“distribution shift”下的外推能力评估缺少理论工具。

做了有什么价值：可为政策制定者模拟不同碳排路径下的经济与能源走势。

[1] Barredo Arrieta A, Díaz-Rodríguez N, et al. Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI[J]. Information Fusion, 2019, 58: 82-115.

[2] Kairouz P, McMahan H B, et al. Advances and Open Problems in Federated Learning[J]. Foundations and Trends® in Machine Learning, 2021, 14(1-2): 1-210.

[3] Staffell I, Scamman D, et al. The role of hydrogen and fuel cells in the global energy system[J]. Energy & Environmental Science, 2019, 12(2): 463-491.

[4] Andoni M, Robu V, et al. Blockchain technology in the energy sector: A systematic review of challenges and opportunities[J]. Renewable and Sustainable Energy Reviews, 2019, 100: 143-174.

[5] Armaroli N, Balzani V. The Future of Energy Supply: Challenges and Opportunities

二

- [1] Alejandro Barredo Arrieta, Natalia Díaz-Rodríguez, Javier Del Ser, 等. Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 2019. doi:10.1016/j.inffus.2019.12.012.
- [2] Peter Kairouz, H. Brendan McMahan, Brendan Avent, 等. Advances and Open Problems in Federated Learning. *Foundations and Trends® in Machine Learning*, 2020. doi:10.1561/22000000083.
- [3] Iain Staffell, Daniel Scamman, Anthony Velazquez Abad, 等. The role of hydrogen and fuel cells in the global energy system. *Energy & Environmental Science*, 2018. doi:10.1039/c8ee01157e.
- [4] Merlinda Andoni, Valentin Robu, David Flynn, 等. Blockchain technology in the energy sector: A systematic review of challenges and opportunities. *Renewable and Sustainable Energy Reviews*, 2018. doi:10.1016/j.rser.2018.10.014.
- [5] Nicola Armaroli, Vincenzo Balzani. *The Future of Energy Supply: Challenges and Opportunities*. *Angewandte Chemie International Edition*, 2006. doi:10.1002/anie.200602373.
- [6] Marc Rysman. The Economics of Two-Sided Markets. *The Journal of Economic Perspectives*, 2009. doi:10.1257/jep.23.3.125.
- [7] Vincent François-Lavet, Peter Henderson, Riashat Islam, 等. An Introduction to Deep Reinforcement Learning. *Foundations and Trends® in Machine Learning*, 2018. doi:10.1561/22000000071.
- [8] Paul Veers, Katherine Dykes, Eric Lantz, 等. Grand challenges in the science of wind energy. *Science*, 2019. doi:10.1126/science.aau2027.
- [9] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, 等. Toward Causal Representation Learning. *Proceedings of the IEEE*, 2021. doi:10.1109/jproc.2021.3058954.
- [12] Ioannis Antonopoulos, Valentin Robu, Benoit Couraud, 等. Artificial intelligence and machine learning approaches to energy demand-side response: A systematic review. *Renewable and Sustainable Energy Reviews*, 2020. doi:10.1016/j.rser.2020.109899.
- [14] Hamed Ghoddusi, Germán G. Creamer, Nima Rafizadeh. Machine learning in energy economics and finance: A review. *Energy Economics*, 2019. doi:10.1016/j.eneco.2019.05.006.
- [21] Pierre Friedlingstein, Michael O'Sullivan, Matthew W. Jones, 等. Global Carbon Budget 2023. *Earth system science data*, 2023. doi:10.5194/essd-15-5301-2023.
- [23] Jian Liu, Hongqiang Wang, Markus Antonietti. Graphitic carbon nitride “reloaded”: emerging applications beyond (photo)catalysis. *Chemical Society Reviews*, 2016. doi:10.1039/c5cs00767d.
- [52] Nivethitha Somu, M. R. Gauthama Raman, Krithi Ramamritham. A deep learning framework for building energy consumption forecast. *Renewable and Sustainable Energy Reviews*, 2020. doi:10.1016/j.rser.2020.110591.
- [53] Zhe Wang, Tianzhen Hong, Mary Ann Piette. Building thermal load prediction through shallow machine learning and deep learning. *Applied Energy*, 2020. doi:10.1016/j.apenergy.2020.114683.

[54] Jatin Bedi, Durga Toshniwal. Deep learning framework to forecast electricity demand. *Applied Energy*, 2019. doi:10.1016/j.apenergy.2019.01.113.

## n

[17] Jared Willard, Xiaowei Jia, Shaoming Xu, 等. Integrating Scientific Knowledge with Machine Learning for Engineering and Environmental Systems. *ACM Computing Surveys*, 2022. doi:10.1145/3514228.

[41] Ozan Nadingil. Carbon price prediction using multiple hybrid machine learning models optimized by genetic algorithm. *Journal of Environmental Management*, 2023. doi:10.1016/j.jenvman.2023.118061.

[57] M. A. Ganaie, Minghui Hu, A. K. Malik, 等. Ensemble deep learning: A review. *Engineering Applications of Artificial Intelligence*, 2022. doi:10.1016/j.engappai.2022.105151.

[59] Heng Shi, Minghao Xu, Ran Li. Deep Learning for Household Load Forecasting—A Novel Pooling Deep RNN. *IEEE Transactions on Smart Grid*, 2017. doi:10.1109/tsg.2017.2686012.

[60] Xueheng Qiu, Ye Ren, Ponnuthurai Nagaratnam Suganthan, 等. Empirical Mode Decomposition based ensemble deep learning for load demand time series forecasting. *Applied Soft Computing*, 2017. doi:10.1016/j.asoc.2017.01.015.

[63] Mohamad Khalil, A. Stephen McGough, Zoya Pourmirza, 等. Machine Learning, Deep Learning and Statistical Analysis for forecasting building energy consumption — A systematic review. *Engineering Applications of Artificial Intelligence*, 2022. doi:10.1016/j.engappai.2022.105287.

## O

[18] Spyros Makridakis, Evangelos Spiliotis, Vassilios Assimakopoulos. Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 2018. doi:10.1371/journal.pone.0194889.